1. Propósito del taller

En este laboratorio se construirá una aplicación capaz de crear un dinosaurio ficticio. El trabajo seguirá cuatro etapas: generar un nombre, definir las características de la especie, producir su imagen e integrar los resultados en un chat.

Cada etapa utilizará el resultado de la anterior. El producto final deberá completar este recorrido sin evaluación automática ni una arquitectura obligatoria.

2. Generador de nombres

¡Bienvenido a la Isla de los Dinosaurios! Los investigadores están creando nuevas especies y necesitan nombres que conserven algunos patrones de los dinosaurios conocidos sin copiar los existentes. Para ayudarlos, construya un modelo que aprenda a predecir el siguiente carácter de un nombre. Durante la generación, cada carácter producido se utiliza para predecir el siguiente; este funcionamiento se denomina *autoregresivo*.



Welcome the MANGOSAURUS !

Datos

Utilice el conjunto `dinos.csv` indicado para el laboratorio.

Preprocesamiento

Prepare los nombres en el siguiente orden:

- normalice el texto para aplicar un mismo criterio de escritura;
- construya el vocabulario, es decir, la relación entre cada carácter y su identificador numérico;
- agregue tokens especiales para señalar el inicio y el final de cada nombre;
- establezca la longitud máxima T a partir de las secuencias preparadas;
- complete las secuencias más cortas con el token `<PAD>` para que tengan la misma longitud;
- construya las secuencias de entrada y objetivo con un desplazamiento de un carácter.

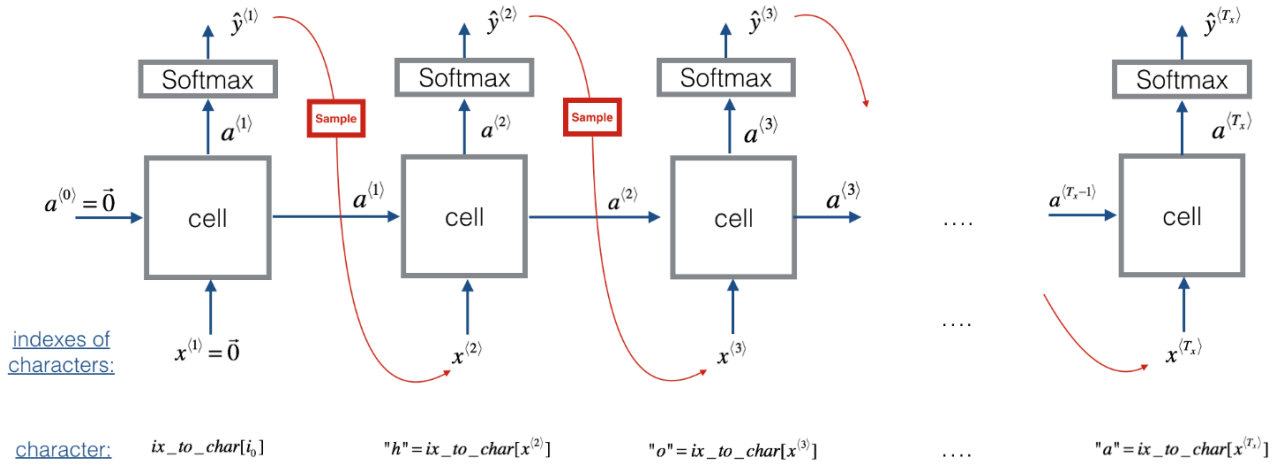
Para una secuencia $[x_0, x_1, \ldots, x_T]$, utilice:

$$X = [x_0, x_1, \ldots, x_{T-1}], \qquad Y = [x_1, x_2, \ldots, x_T].$$

Modelo y entrenamiento

Implemente el modelo con celdas recurrentes RNN, LSTM o GRU. El estado oculto conserva información de los caracteres procesados y permite utilizar ese contexto para realizar la siguiente predicción.

Durante el entrenamiento, la función de pérdida mide el error de las predicciones y el optimizador ajusta los parámetros del modelo. Evalúe dos configuraciones y registre la arquitectura, el número de capas, el tamaño del estado oculto, las épocas, la función de pérdida y el optimizador. El token `<PAD>` deberá excluirse del cálculo de la pérdida. Utilice datos de entrenamiento para ajustar el modelo y datos de validación para observar su comportamiento; presente las curvas de pérdida de ambos conjuntos.



Esquema de generación autoregresiva suministrado en el documento base del laboratorio.

Generación y muestreo

En cada paso, el modelo produce una distribución de probabilidades sobre el vocabulario. Compare estas estrategias para seleccionar el siguiente carácter:

- **Temperatura:** modifica la concentración de las probabilidades; los valores bajos favorecen opciones previsibles y los altos aumentan la diversidad.
- **Top-k:** limita la selección a los *k* caracteres con mayor probabilidad.
- **Top-p:** considera el conjunto más pequeño de caracteres cuya probabilidad acumulada alcanza el valor *p*.

Utilice por lo menos tres temperaturas, una de ellas igual a 1.0, y seleccione valores de *top-k* y *top-p* que permitan observar diferencias. No es necesario evaluar todas las combinaciones posibles.

Presente diez nombres que no coincidan exactamente con los del conjunto de entrenamiento. Incluya una comparación breve de los resultados y seleccione uno como resultado de esta etapa.

3. Creación de la especie con Ollama

Ollama permite ejecutar un modelo de lenguaje en la infraestructura del equipo, sin enviar las solicitudes a un proveedor externo. Utilícelo para construir la identidad del dinosaurio seleccionado dentro de una instancia de notebook de SageMaker.

Configuración

- Cree un notebook de SageMaker con una instancia `m5.xlarge`.
- Instale Ollama mediante Docker.
- Descargue un modelo compatible con los recursos disponibles y registre su nombre y versión.
- Compruebe desde el notebook que el modelo recibe una instrucción y devuelve una respuesta.

No se permite sustituir esta instalación por el servicio de un proveedor externo.

Identidad del dinosaurio

A partir del nombre seleccionado, solicite una descripción que incluya apariencia, hábitat, alimentación, comportamiento y una característica distintiva. Puede ofrecer al modelo ejemplos breves de prefijos o sufijos presentes en nombres reales, como *-saurus*, *-raptor*, *-odon* o *-venator*.

La descripción resultante será la identidad del dinosaurio. La especie es ficticia, pero sus rasgos deben mantener coherencia entre sí. Conserve esta descripción porque será la entrada de las etapas siguientes.

Persistencia del entorno

Guarde los archivos necesarios dentro de `/home/ec2-user/SageMaker`, que corresponde al espacio persistente del notebook. Docker almacena sus imágenes y contenedores en una ruta denominada `data-root`; configure esa ruta dentro del directorio persistente. Cree también un *lifecycle script* `on-start`, es decir, un script que aplique esta configuración cada vez que se inicie el notebook.

4. Generación de la imagen

Un modelo *text-to-image* convierte una instrucción escrita en una imagen. Utilice este tipo de modelo para representar al dinosaurio descrito en la sección anterior. Puede ejecutarlo en Google Colab o en un entorno equivalente con GPU.

- Configure un entorno con GPU e instale las librerías necesarias, como `diffusers`, `transformers`, `torch`, `accelerate` y `safetensors`.
- Seleccione un modelo compatible con los recursos disponibles. Puede utilizar `amused/amused-512` u otra alternativa de tamaño similar.
- Redacte el *prompt*, o instrucción de entrada, con el nombre y los rasgos definidos por Ollama.
- Genere una imagen para el dinosaurio seleccionado. No se requieren imágenes para los diez nombres obtenidos en la etapa de generación.

Utilice un *prompt* conciso y una resolución compatible con los recursos disponibles.

5. Integración y chat con el dinosaurio

En este punto ya se dispone del nombre, la identidad y la imagen. Construya una aplicación web que conecte estos resultados en el siguiente flujo:

$$\text{Modelo de caracteres} \rightarrow \text{Nombre} \rightarrow \text{Ollama} \rightarrow \text{Identidad} \rightarrow \text{Imagen} \rightarrow \text{Chat}.$$

Comience por mostrar el nombre, la descripción y la imagen del dinosaurio, junto con información básica sobre el modelo utilizado para crear el nombre.

Después, agregue el chat. Envíe a Ollama la descripción conservada en la sección 3 como contexto para cada conversación. Las respuestas pueden ampliar esa información, pero no deben contradecir los rasgos principales de la especie. Cuando el dinosaurio se presente o el usuario solicite su descripción, el mensaje deberá incluir también su imagen. La imagen se genera una sola vez por dinosaurio y se reutiliza durante el chat.

La interfaz incluirá un botón **Nuevo Dinosaurio**. Al utilizarlo, el modelo ya entrenado generará otro nombre y se repetirá el proceso de descripción e imagen; no se volverá a entrenar el modelo recurrente.

Para conectar la aplicación con Ollama o con el generador de imágenes, puede utilizar ngrok, el cual crea una dirección pública temporal hacia el servicio alojado en SageMaker, Colab o un equipo local. También puede emplear una función AWS Lambda como intermediario o proxy para orquestar las peticiones. No se exige una tecnología ni una estructura de comunicación predeterminadas, pero el repositorio debe documentar qué información recibe y devuelve cada componente.

Cuando el flujo funcione de manera integrada, despliegue la aplicación web en AWS. El modelo de generación de imágenes puede permanecer en Colab o ejecutarse localmente.

6. Entregables

- Enlace al sitio web funcionando;
- Enlace al repositorio, que deberá contener el generador de nombres, la configuración de Ollama, el código de generación de imágenes y los archivos de la aplicación;
- README con instrucciones breves para identificar y ejecutar los componentes.

El repositorio no debe contener credenciales, claves de acceso, tokens utilizados por las herramientas ni otra información sensible.

7. Evidencias del trabajo experimental

Incluya en el repositorio estas evidencias del trabajo con el generador de nombres:

- Arquitectura y configuración del modelo;
- curvas de pérdida de entrenamiento y validación;
- Configuraciones de muestreo utilizadas;
- Diez nombres generados y un análisis breve de los resultados.

8. Evaluación

Componente	Criterio	Valor
Sustentación	Un integrante explicará el modelo de caracteres, las decisiones experimentales, el uso de Ollama, la generación de la imagen y la integración.	1.5
Repositorio y arquitectura completa	Se verificará el flujo nombre → identidad → imagen → chat, además de la organización y las instrucciones de ejecución.	2.5
Metodología y seguimiento de los experimentos	Se revisarán las configuraciones, las curvas de entrenamiento y validación, el muestreo y el análisis de los nombres.	1.0
Total		**5.0**

9. Verificación antes de la entrega

Compruebe que:

- Los diez nombres generados no sean copias directas del conjunto de entrenamiento;
- El dinosaurio seleccionado tenga una identidad coherente;
- La imagen corresponda con los rasgos descritos;
- El chat conserve la identidad durante la conversación;
- La imagen aparezca en el chat al presentar o describir al dinosaurio;
- El botón **Nuevo Dinosaurio** inicie una nueva generación sin reentrenar el modelo;
- El sitio web sea accesible;
- El repositorio contenga las instrucciones necesarias y no publique información sensible.